

Informe final - Proyecto Integrador Minería de Datos I

Integrante: Ignacio Fonzo | Julio 2026

1. Contexto y objetivo

Se analizó un dataset de usuarios de una plataforma de streaming de Latinoamérica con el objetivo de aplicar el proceso completo de minería de datos (inspección, limpieza documentada, EDA, escalamiento y PCA) y responder cinco preguntas: distribución del consumo (P1), consumo por plan (P2), relación edad-consumo (P3), preferencias de género por país (P4) y posibilidad de reducir dimensionalidad (P5).

2. Dataset y calidad inicial

El archivo original contiene 8.160 registros y 8 variables; cada registro es un usuario (edad, país, plan, minutos vistos por mes, género favorito, último acceso y tickets de soporte). La inspección documentó: 160 registros duplicados; valores imposibles (edades de -5 a 150, minutos negativos, centinela 99999, tickets -1/99/150); 69 variantes de escritura para 17 categorías reales en plan, país y género; y fechas con dos formatos mezclados, valores inexistentes (31-02-2022, 0000-00-00) y futuros (2029-01-01).

3. Decisiones de limpieza y preparación

Cada transformación siguió el esquema evidencia-decisión-impacto y quedó registrada en logs/pipeline_log.csv. Se eliminaron solo los duplicados (8.160 a 8.000 filas, retención 98%). Las categóricas se unificaron a 3 planes, 7 países y 7 géneros (los 240 géneros faltantes pasaron a 'Desconocido'). Los valores imposibles se convirtieron a faltante y se imputaron con medianas (mediana por plan para el consumo, dado que el consumo depende fuertemente del plan). Las fechas inválidas o futuras quedaron como faltantes (7,6% final) sin eliminar usuarios, y se derivó la variable de recencia days_since_last_login (referencia: 2026-07-04).

Paso	Filas	Retención
Estado inicial	8.160	100%
Duplicados exactos y por user_id eliminados	8.000	98%
Normalizaciones, imputaciones y fechas (sin pérdida)	8.000	98%

4. Hallazgos del análisis exploratorio

P1: el consumo mensual es asimétrico a la derecha: la mediana es de ~770 minutos (unas 13 horas) con una cola de usuarios intensivos que infla el promedio; el proyecto reporta medianas. P2 (hallazgo principal): el consumo escala con el plan: medianas de 553 (Básico), 840 (Estándar) y 1.127 minutos (Premium); un usuario Premium típico mira el doble que uno Básico y el patrón se repite en los 7 países. Básico concentra el 45% de la base, por lo que los básicos de alto consumo son candidatos a upgrade. P3: la edad no se relaciona con el consumo ($r = 0,006$). P4: las preferencias de género son homogéneas entre países (cada género representa entre 12% y 16% en todos los mercados). Además, las cuatro variables numéricas están incorrelacionadas entre sí ($|r| < 0,02$).

5. Escalamiento y PCA

Se aplicó PCA sobre las cuatro numéricas de comportamiento (edad, minutos mensuales, tickets y días desde el último acceso), estandarizadas con StandardScaler por sus escalas dispares, sobre las 7.390 filas con fecha válida. La varianza explicada resultó casi uniforme (25,5 / 25,0 / 24,8 / 24,6%): se necesitan 3 de 4 componentes para el 75%. Coherente con la ausencia de correlación, no existe redundancia que comprimir: cada variable aporta una dimensión independiente y los planes no forman grupos separados en el plano PC1-PC2.

6. Conclusiones y limitaciones

El plan de suscripción es el mejor diferenciador del comportamiento disponible en el dataset; la edad, los tickets y la recencia no aportan segmentación, y PCA confirma que la estructura del dataset está en las variables categóricas y no en combinaciones lineales de las numéricas. Limitaciones: el alcance de las conclusiones está condicionado por la información disponible y por las decisiones documentadas (imputaciones incluidas); el corte es transversal, sin dimensión temporal, y no permite establecer causalidad; un 7,6% de los usuarios carece de fecha de último acceso válida; el género favorito es declarado y único por usuario. Como mejora futura, incorporar historial de visualizaciones e ingresos por usuario permitiría ampliar el análisis hacia retención y valor del cliente.

7. Enlaces

Repositorio: <https://github.com/nachof9/Mineria-de-datos-1>

Aplicación: <https://COMPLETAR.streamlit.app>